
From Raw Detections to Real Intelligence

Um Pipeline Híbrido de Visão Computacional, Analytics e IA Generativa

Marco Alves

Nº: 53589

Inteligência Artificial e Ciência de Dados

Interação com Modelos de Larga Escala

Maio de 2026

Conteúdo

1	Introdução	3
1.1	Contextualização e Motivação	3
1.2	Objetivos do Projeto	3
2	Arquitetura do Sistema	4
2.1	Stack Tecnológica e Justificação	4
2.2	Fluxo de Dados Detalhado	4
3	Metodologia de Implementação	5
3.1	O Algoritmo de Stitching	5
3.1.1	Heurística Demográfica	5
3.1.2	Restrições de Transição Espacial	5
3.2	Motor de Analytics e KPIs de Retalho	6
4	Engenharia de Prompts e Inteligência Narrativa	6
4.1	Estratégia A: Zero-Shot Prompting	6
4.2	Estratégia B: Few-Shot Prompting	7
4.2.1	Iterações e Evolução dos Prompts	7
4.3	Comparação Quantitativa e Qualitativa	7
4.4	Análise de Exemplos de Output	8
5	Resultados e Discussão Crítica	9
5.1	Avaliação Quantitativa do Pipeline	9
5.2	Impacto Operacional e Qualidade dos Insights	9
6	Ética, Privacidade e Conformidade	9
7	Conclusões e Evolução	10
7.1	Principais Conclusões	10
7.2	Limitações e Desafios Futuros	10

1 Introdução

1.1 Contextualização e Motivação

No atual paradigma do retalho físico, a competição com o comércio eletrónico exige um nível de compreensão do cliente sem precedentes. Enquanto plataformas digitais monitorizam cada clique, cada visualização de produto e cada abandono de carrinho com precisão cirúrgica, o retalho físico ainda debate-se com a fragmentação de dados. Os sistemas de visão computacional modernos, embora capazes de detetar pessoas e atributos com elevada fidelidade, operam frequentemente de forma isolada para garantir a privacidade do utilizador final. O resultado são “eventos de deteção” desconexos e não “jornadas de cliente” contínuas. Esta fragmentação ocorre devido a fatores intrínsecos ao ambiente físico de uma loja:

- **Oclusões:** Estruturas de prateleiras, expositores de marketing ou outros clientes que interrompem momentaneamente a linha de vista da câmara, gerando novos identificadores para a mesma pessoa.
- **Limitações de Hardware:** Zonas mortas entre os campos de visão de diferentes câmaras onde o cliente não é monitorizado.
- **Privacidade por Design:** A ausência deliberada de identificadores biométricos persistentes (como reconhecimento facial) impede o rastreio automático entre visitas ou mesmo entre secções distantes da loja.

1.2 Objetivos do Projeto

O presente trabalho propõe resolver esta lacuna através de um pipeline que não só liga os pontos (reconstrução de trajetórias), mas também traduz a complexidade estatística para linguagem humana estratégica. Os objetivos específicos incluem:

1. Desenvolver um algoritmo de *stitching* resiliente a ruído que normalize jornadas fragmentadas.
2. Implementar um motor de cálculo de métricas de funil (*conversion funnel*) e permanência (*dwell time*) por zona.
3. Integrar modelos LLM locais (Ollama) para a geração de relatórios semanais que sintetizem tendências e anomalias.
4. Validar a robustez da solução através de métricas rigorosas de cobertura e completude estatística.

2 Arquitetura do Sistema

A arquitetura do sistema segue um modelo de camadas desacopladas, permitindo que cada módulo seja escalado ou substituído sem comprometer a integridade global. O pipeline foi implementado em Python 3.14, utilizando uma pilha tecnológica moderna focada em performance, segurança e tipagem forte.

2.1 Stack Tecnológica e Justificação

A seleção das ferramentas baseou-se no equilíbrio entre eficiência de desenvolvimento e performance em tempo de execução:

- **Processamento de Dados:** Pandas e NumPy para manipulação eficiente de matrizes e tabelas de eventos.
- **Validação de Esquemas:** Pydantic para garantir que os ficheiros de configuração (`zones.json`) e os eventos brutos respeitam rigorosamente o contrato de dados esperado.
- **IA Generativa:** Ollama com o modelo `llama3.1:8b` (8 mil milhões de parâmetros), escolhido pela sua excelente capacidade de raciocínio lógico em hardware limitado.
- **Interface de Saída:** Geração de relatórios em *Markdown* para consumo humano e *JSON* para integração com sistemas de terceiros.

2.2 Fluxo de Dados Detalhado

O fluxo inicia-se com a leitura de ficheiros CSV contendo eventos brutos capturados pelos sensores. Cada evento contém um carimbo temporal (*timestamp*), ID de zona, género, idade estimada e o tipo de interação registado.

Fluxo Lógico de Transformação

1. **Ingestão:** Validação de tipos e ordenação cronológica rigorosa.
2. **Stitching:** Algoritmo de unificação de trajetórias fragmentadas.
3. **Analytics:** Agregação estatística por zona, jornada e demografia.
4. **Enrichment:** Detecção de anomalias baseada em desvio padrão histórico.
5. **Synthesis:** Orquestração do LLM para geração da narrativa final.

3 Metodologia de Implementação

3.1 O Algoritmo de Stitching

O módulo `stitcher.py` é o núcleo técnico do projeto. Ele implementa um sistema de associação baseada em regras (*Rule-based Association*) que utiliza proximidade temporal, espacial e demográfica. Ao contrário de abordagens puramente probabilísticas que podem introduzir “alucinações” de trajetórias, este algoritmo foca-se em restrições físicas do mundo real.

3.1.1 Heurística Demográfica


Para que dois eventos capturados em momentos diferentes sejam associados à mesma pessoa, o sistema exige uma coincidência exata no género e uma proximidade na faixa etária. Embora os modelos de visão computacional possam ter erros de estimação, a combinação destes atributos demográficos atua como uma “impressão digital anónima” que reduz drasticamente o espaço de erro do algoritmo.

3.1.2 Restrições de Transição Espacial

O sistema utiliza um grafo de adjacências definido em `zones.json`. Para cada par de zonas, define-se um tempo mínimo de caminhada (`walk_seconds`).

$$\Delta t_{\text{transição}} = t_{\text{entrada_Z2}} - t_{\text{saída_Z1}} \geq \text{walk_seconds}(Z_1, Z_2) \quad (1)$$

Se a diferença de tempo for fisicamente impossível de percorrer, o algoritmo rejeita a associação e inicia uma nova jornada de cliente.



```

1  for pid in potential_pids:
2      p = active_people[pid]
3      if p['current_zone'] is None and p['last_exit_time'] is not None:
4          time_diff = (ts - p['last_exit_time']).total_seconds()
5
6          if 0 <= time_diff <= 300:
7              if p['last_zone'] in zones and z_id in zones[p['last_zone']]['walk_seconds']:
8                  if time_diff < zones[p['last_zone']]['walk_seconds'][z_id]:
9                      continue
10
11             if time_diff < min_time_diff:
12                 min_time_diff = time_diff
13                 best_match = pid

```

Interface do Stitcher: Demonstração da consolidação de múltiplos eventos numa jornada única e coerente.

3.2 Motor de Analytics e KPIs de Retalho

O componente `analytics.py` transforma as jornadas reconstruídas em inteligência de negócio. O motor foca-se em três dimensões principais de análise:

- **Eficiência de Atração (Stop Rate):** Mede a percentagem de clientes que, ao passarem por uma zona, decidem parar e interagir com o produto (permanência > 10 segundos).
- **Retenção (Average Dwell Time):** O tempo médio gasto em cada secção, servindo como indicador de interesse ou, em casos negativos (como o checkout), de ineficiência operacional.
- **Funil de Conversão:** Acompanhamento da progressão do cliente desde as zonas de entrada até à zona de pagamento, identificando onde ocorrem as maiores desistências.

```

1  for _, row in test.iterrows():
2      h, z, c = row['hour_of_day'], row['zone_id'], row['person_id']
3      if (h, z) in stats.index:
4          m, s = stats.loc[(h, z), 'mean'], stats.loc[(h, z), 'std']
5          if s > 0 and abs(c - m) > 2 * s:
6              metrics['anomalies'].append({
7                  'date': str(dates[6].date()) if hasattr(dates[6], 'date') else str(dates[6]),
8                  'hour': int(h), 'zone_id': str(z), 'observed': int(c),
9                  'expected_mean': float(m), 'expected_std': float(s), 'deviation_sigma': float((c - m) / s)
10             })

```

Métricas consolidadas: Distribuição de tráfego por hora e performance de conversão por departamento.

4 Engenharia de Prompts e Inteligência Narrativa

A transformação de métricas JSON em relatórios estratégicos é realizada pelo módulo `insights.py`. Seguindo o enunciado do projeto, foram implementadas e comparadas duas estratégias distintas de prompting para o modelo `llama3.1:8b`.

4.1 Estratégia A: Zero-Shot Prompting

Na estratégia *Zero-Shot*, o modelo recebe apenas o esquema JSON de acesso e as métricas calculadas, sem qualquer exemplo prévio.

- **Vantagem:** Menor consumo de tokens e maior simplicidade de implementação.
- **Dificuldade:** O modelo tende a gerar observações genéricas (ex: “O tráfego aumentou”) sem citar números específicos ou IDs de zonas de forma consistente.

4.2 Estratégia B: Few-Shot Prompting

A estratégia *Few-Shot* utiliza exemplos de “Bons Insights” e “Maus Insights” para guiar o comportamento do modelo. Esta técnica provou ser essencial para garantir o rigor técnico exigido.

4.2.1 Iterações e Evolução dos Prompts

O desenvolvimento dos prompts não foi linear, tendo passado por várias iterações documentadas:

1. **v1 (Base)**: Instruções simples de resumo. O modelo ignorava frequentemente o esquema JSON de saída.
2. **v2 (Refinada)**: Adição de restrições de linguagem (Português de Portugal) e obrigatoriedade de incluir métricas concretas.
3. **v3 (Final)**: Introdução dos exemplos *few-shot* para garantir que as recomendações eram acionáveis e específicas por zona.

4.3 Comparação Quantitativa e Qualitativa

Como podemos analisar através dos dados estruturados na Tabela 1, a abordagem por demonstração superou consistentemente o método direto em todas as métricas críticas de validação.

Tabela 1: Comparação entre Estratégias de Prompting

Critério de Avaliação	Zero-Shot (A)	Few-Shot (B)
Aderência ao Esquema JSON	85%	100%
Utilização de Métricas Reais	60%	100%
Natureza Acionável da Sugestão	Baixa	Alta
Precisão dos IDs de Zona	75%	100%

4.4 Análise de Exemplos de Output

A diferenciação qualitativa entre os resultados gerados por ambas as técnicas de engenharia de prompts encontra-se detalhada na Tabela 2, realçando o ganho de especificidade operacional.

Tabela 2: Diferenciação entre Insights Genéricos e Específicos

Mau Insight (Zero-Shot)	Bom Insight (Few-Shot)
“A zona de frescos teve bastante tráfego esta semana. Recomenda-se melhorar o atendimento.”	“A zona Z_S3 teve 847 visitantes na quinta-feira, 31% acima da média. Possível stockout iminente.”
“Houve uma anomalia na loja no domingo.”	“No domingo às 16h, Z_N4 teve 0 visitantes (média de 23). Possível obstrução de corredor.”

```

1 MAU INSIGHT (Genérico): "A zona de frescos teve bastante tráfego."
2 BOM INSIGHT (Específico): "A zona Z_S3 teve 847 visitantes na quinta-feira, 31% acima da média semanal."
3
4 MAU INSIGHT (Vago): "Recomenda-se melhorar o atendimento ao cliente."
5 BOM INSIGHT (Açãoável): "Às quartas entre 12h-13h, o tempo médio de espera em Z_C2 foi 4,2 minutos – abrir uma terceira caixa neste slot reduziria o tempo para < 2 minutos com base no volume observado."
6
7 MAU INSIGHT: "Houve uma anomalia na loja."
8 BOM INSIGHT: "No domingo às 16h, Z_N4 teve 0 visitantes contra uma média de 23 – possível obstrução ou problema de sinalização."
9
10 Métricas da última semana:
11 {{METRICS}}
12
13 Gera insights acionáveis em Português seguindo rigorosamente este esquema JSON:
14 {
15   "insights": [
16     {
17       "id": "INS_XXX",
18       "categoria": "trafego|zona|funil|anomalia|demografico",
19       "titulo": "Resumo curto",
20       "observacao": "Factos e números concretos",
21       "implicacao": "Significado operacional",
22       "recomendacao": "Ação concreta",
23       "urgencia": "imediatesta_semana|proximo_mes",
24       "confianca": 0.0 a 1.0
25     }
26   ],
27   "resumo_executivo": "3 bullets com os pontos mais criticos (máximo 150 palavras no total)"
28 }
29

```

Configuração final da estratégia Few-Shot no sistema Ollama.

5 Resultados e Discussão Crítica

5.1 Avaliação Quantitativa do Pipeline

Os testes foram realizados utilizando um *dataset* de validação com eventos conhecidos para aferir a precisão do sistema através do `evaluate.py`. Os indicadores de performance consolidados encontram-se mapeados na Tabela 3.

Tabela 3: Resultados da Validação do Pipeline

Indicador de Performance	Resultado Final
Consistência de Trajetórias	100.0%
Cobertura de Eventos Processados	100.0%
Compleitude das Jornadas Reconstruídas	63.1%
Precisão Numérica dos Insights (LLM)	100.0%

Como evidenciado na Tabela 3, a análise da **Compleitude** (63.1%) revela a natureza conservadora do algoritmo. Em ambientes de retalho muito congestionados, o sistema prefere fragmentar uma jornada ambígua do que criar uma associação falsa. Esta decisão é estratégica: para um gestor de retalho, é preferível ter menos dados mas 100% precisos, do que ter volumes inflacionados por erros de associação.

5.2 Impacto Operacional e Qualidade dos Insights

O relatório semanal gerado (`weekly_report.md`) demonstrou uma capacidade notável de síntese. O modelo identificou corretamente que a diminuição de 15% no tráfego da zona Z_N3 estava correlacionada com um aumento de permanência na zona adjacente, sugerindo uma possível barreira física ou mudança no layout da loja que estava a dificultar o fluxo natural dos clientes.

6 Ética, Privacidade e Conformidade

O sistema foi desenhado para ser totalmente *GDPR-compliant*. Não existe armazenamento de rostos, impressões digitais ou qualquer identificador que permita re-identificar um indivíduo fora do contexto daquela visita específica. A utilização de IA local (`Ollama`) garante que os dados de tráfego e vendas da loja nunca cruzam a fronteira da rede interna, protegendo o segredo de negócio e a privacidade dos clientes de forma absoluta.

7 Conclusões e Evolução

7.1 Principais Conclusões

Este trabalho validou que é possível construir um sistema de inteligência de retalho sofisticado utilizando ferramentas de código aberto e modelos de IA locais. A transição de “deteções brutas” para “narrativas estratégicas” representa um salto qualitativo na forma como os gestores de espaços físicos podem competir com as métricas do mundo digital.

7.2 Limitações e Desafios Futuros

Apesar do sucesso, identificaram-se oportunidades de melhoria:

- **Escalabilidade Vertical:** Otimizar o algoritmo de *stitching* para lidar com dezenas de milhares de eventos simultâneos usando processamento paralelo (**Multiprocessing**).
- **Fidelidade Demográfica:** Integrar modelos de visão computacional mais recentes para reduzir a variabilidade na estimação da idade.
- **Visualização de Dados:** Desenvolver um dashboard interativo (ex: **Streamlit**) que permita explorar visualmente as trajetórias reconstruídas sobre o mapa da loja.